Machine Learning — Resolução de Questões

Questão 1 — Classificador k-NN

a) Técnicas de Pré-processamento

Sim, seria necessário aplicar normalização/padronização. Analisando o gráfico, os eixos possuem escalas diferentes (X até ~700, Y até ~1000). Como o k-NN classifica com base em distâncias (geralmente Euclidiana), a feature com maior escala domina automaticamente o cálculo, distorcendo os resultados.

Técnica indicada: Normalização Min-Max (escala 0–1) ou Padronização Z-score (média 0, desvio padrão 1), pois colocam ambas as dimensões em escalas equivalentes, garantindo peso proporcional no cálculo da distância.

Adicionalmente, o gráfico revela desbalanceamento de classes (classe Minoritária — azul — com muito menos amostras que a Majoritária — vermelha). Nesse caso, técnicas como SMOTE (oversampling da classe minoritária) ou undersampling da majoritária seriam relevantes para evitar que o classificador seja tendencioso.

b) Variação do k-NN mais adequada

A variação mais adequada seria o k-NN Ponderado pela Distância (Distance-Weighted k-NN).

Justificativa: Há uma região de sobreposição considerável entre as duas classes (aproximadamente entre x=200 e x=500). O k-NN tradicional trata todos os k vizinhos com peso igual, o que pode gerar erros quando um vizinho muito próximo é de uma classe e vários vizinhos mais distantes são de outra. A versão ponderada dá mais influência aos vizinhos mais próximos, sendo mais precisa nesse cenário.

c) Efeito de valores altos e baixos de k

	k-NN Tradicional	k-NN Ponderado
k muito baixo (ex: k=1)	Fronteira irregular, sensível a ruído — overfitting	Mesmo problema; com k=1 o peso não faz diferença
k muito alto (ex: k=50+)	Fronteira suave, pode ignorar padrões — underfitting. Classe majoritária domina	Peso pela distância atenua o problema; vizinhos distantes têm menor influência

Conclusão: Para esse conjunto, com desbalanceamento e sobreposição de classes, um k moderado (entre 5 e 15) com ponderação pela distância é o mais indicado. Valores muito baixos geram instabilidade e valores muito altos tendem a classificar quase tudo como Majoritária, prejudicando a detecção da classe Minoritária.

Questão 2 — Naive Bayes

Dados de Treinamento

Total: 13 instâncias — 7 positivas (+) e 6 negativas (−)

Exame A	Exame B	Classe
H	C	+
R	B	+
R	C	+
H	B	+
J	B	+
R	C	−
J	C	−
J	B	−
H	C	+
J	C	−
R	C	−
J	B	+
R	C	−

a) Tabela de Frequências e Probabilidades

Probabilidades a priori:

P(+) = 7/13 ≈ 0,538 P(−) = 6/13 ≈ 0,462

Frequências — Exame A:

Exame A	Freq (+)	Freq (−)	Total
H	3	**0**	3
R	2	3	5
J	2	3	5
Total	**7**	**6**	**13**

Frequências — Exame B:

Exame B	Freq (+)	Freq (−)	Total
B	4	1	5
C	3	5	8
Total	**7**	**6**	**13**

Necessidade de suavização: SIM. O valor H na classe (−) tem frequência 0, o que geraria probabilidade zero e anularia todo o produto no Naive Bayes. Aplicamos o Estimador de Laplace com α = 1.

Fórmula com Laplace: $P(x_i \mid C) = (freq(x_i, C) + 1) / (total(C) + |V|)$
onde |V| é o número de valores possíveis do atributo.

Probabilidades Suavizadas — Exame A (|V| = 3: H, R, J):

Exame A	P(x | +)	P(x | −)	Cálculo (+) / (−)
H	0,400	0,111	(3+1)/(7+3) / (0+1)/(6+3)
R	0,300	0,444	(2+1)/(7+3) / (3+1)/(6+3)
J	0,300	0,444	(2+1)/(7+3) / (3+1)/(6+3)

Probabilidades Suavizadas — Exame B (|V| = 2: B, C):

Exame B	P(x | +)	P(x | −)	Cálculo (+) / (−)
B	0,556	0,250	(4+1)/(7+2) / (1+1)/(6+2)
C	0,444	0,750	(3+1)/(7+2) / (5+1)/(6+2)

b) Classificação do Conjunto de Teste

Para classificar cada instância calcula-se: $score(C) = P(C) \times P(A|C) \times P(B|C)$
A classe com maior score é a predita.

#	Exame A	Exame B	Score (+)	Score (−)	Predito	Real	Resultado
1	R	B	0,0898	0,0513	+	+	✓
2	J	B	0,0898	0,0513	+	−	✗
3	J	C	0,0717	0,1540	−	−	✓
4	R	C	0,0717	0,1540	−	+	✗
5	H	C	0,0956	0,0385	+	+	✓

Taxa de erro = 2/5 = 0,4 = 40% | **Acurácia = 60%**