

Relatório Técnico: Análise Avançada e Engenharia de Recursos na Classificação de Soquetes de CPU

1. Identificação da Equipe

- **Augusto Palma Guglielmi** — RA: 23021606-2
- **Fabício Notoya Thomas** — RA: 23082446-2
- **Guilherme Pitão Garcia** — RA: 23000966-2
- **Pietro Pasqual Silva** — RA: 23183509-2
- **Thiago Lopes Martins** — RA: 23016365-2

2. Resumo do Projeto

Contextualização e Definição do Problema

A triagem, identificação e destinação correta de componentes de hardware são fundamentais em cadeias modernas de logística reversa e reciclagem eletrônica sustentável. Este projeto aborda o desenvolvimento de uma solução de Visão Computacional integrada a algoritmos de Inteligência Artificial para classificar soquetes de unidades centrais de processamento (CPUs) contidos em placas-mãe. O escopo inicial estendia-se de forma ambiciosa a 32 classes distintas de soquetes; contudo, restrições práticas ligadas à qualidade de imagem e à necessidade de alta fidelidade matemática impuseram o descarte de amostras inconsistentes, delimitando o problema a 11 modelos viáveis. Posteriormente, diagnósticos estruturais indicaram a necessidade de uma abstração mais robusta, consolidando o objetivo final em uma classificação binária focada nos padrões de arquitetura dos dois principais fabricantes globais: AMD (mecanismo PGA) e Intel (mecanismo LGA).

Hipótese de Trabalho

Postulou-se que a extração de características brutas sem conformidade geométrica ou alinhamento prévio submeteria os modelos preditivos ao efeito da variância espacial, limitando severamente a acurácia. A hipótese da equipe define que a padronização das matrizes por

meio de rotação geométrica coordenada, associada à redução de dimensionalidade e à junção estratégica de classes para uma distinção binária (AMD vs. Intel), eliminaria os ruídos de posicionamento absoluto, habilitando classificadores lineares, métodos baseados em ensemble e redes neurais a superarem o patamar de 90% de acurácia geral.

3. Dinâmica e Evolução da Base de Dados

A construção e o tratamento do dataset representaram o núcleo empírico do projeto, estruturado em quatro fases metodológicas distintas:

- **Dataset V1.0 (Abordagem Cromática Inicial):** Primeira versão estruturada com foco em atributos de cores (RGB) e iluminação. A aplicação do algoritmo Apriori como ferramenta de auditoria revelou multicolinearidade severa com índices de confiança de 98%. Os algoritmos de agrupamento não-supervisionado falharam na separação de clusters consistentes.
- **Dataset V2.0 (Extração de Contornos):** Abandono das variáveis cromáticas em favor de filtros de bordas em escala de cinza distribuídos em 11 classes. Sob esta configuração, os modelos de classificação supervisionada obtiveram um teto de acurácia de 52% com Redes Neurais (MLP) e apenas 33% com Árvore de Decisão.
- **Dataset V3.0 (Padronização por Rotação):** Introdução de um pipeline de processamento de imagens voltado ao alinhamento geométrico por rotação, eliminando o ruído posicional das 11 classes originais.
- **Dataset V3.0 com Junção de Classes (Modelo Final):** Como decisão tomada a partir dos testes exploratórios, as 11 classes específicas foram aglutinadas em duas macro-classes que separam fisicamente as arquiteturas (AMD/PGA vs. Intel/LGA). Os vetores resultantes foram submetidos a escalonamento linear e avaliados sob validação cruzada estratificada (5-fold).

4. Modelos de Inteligência Artificial e Justificativa de Arquitetura


A equipe implementou e comparou os seguintes modelos:

- **Métodos da Parte 1 (Machine Learning Clássico):**
 - *Não-Supervisionados (Auditoria):* K-Means, AGNES e DIANA.
 - *Supervisionados:* Algoritmos preditivos, destacando-se Support Vector Machines (SVM), Random Forest e AdaBoost.
- **Métodos da Parte 2 (Modelos Avançados):** Redes Neurais Artificiais do tipo Multi-Layer Perceptron (MLP), ajustadas por retropropagação.

5. Análise Crítica de Resultados e Regras de Produção

A Falha Visual do Agrupamento Não-Supervisionado

Para evidenciar empiricamente o motivo pelo qual a modelagem inicial falhou, os dados brutos foram submetidos a algoritmos de agrupamento não-supervisionado. O gráfico de dispersão gerado pela redução de dimensionalidade (PCA 2D) e a análise estrutural do Dendrograma abaixo ilustram uma sobreposição extrema das amostras. Os clusters do K-Means e do AGNES provaram-se ineficazes, com o índice de Silhouette beirando a zero, atestando que características sem alinhamento geométrico são insuficientes para separar o hardware autonomamente.



A Evidência do Algoritmo PRISM

O travamento do desempenho na Fase V2.0 e o sucesso na Fase V3.0 foi matematicamente explicitado através das regras indutivas geradas pelo algoritmo PRISM. Após a rotação e a simplificação binária, as regras ganharam a generalização lógica ideal para a Visão Computacional:

Regras Indutivas Geradas pelo PRISM (Modelo Final):

SE dim0 = 0 e dim4 = 0 ENTÃO AMD



SE dim1 = 0 e dim2 = 0 ENTÃO INTEL

Essas regras provam que, ao alinhar geometricamente as imagens, os furos específicos do padrão PGA e as bordas de contato do padrão LGA passaram a ativar índices idênticos e previsíveis nas matrizes de características.

Desempenho Comparativo dos Modelos (V3.0 Final)

Ao rodar a base final (rotacionada e com junção de classes), os modelos baseados em Ensemble (AdaBoost e Random Forest) e o hiperplano do SVM dominaram o ranking de acurácia, refletindo o sucesso da engenharia de características:

Algoritmo Avaliado	Configuração / Dataset Usado	Acurácia Geral Obtida
Árvore de Decisão Clássica	V3.0 Final (Binário / Rotacionado)	84%
Rede Neural MLP	V3.0 Final (Binário / Rotacionado)	92%
Support Vector Machine (SVM)	V3.0 Final (Binário / Rotacionado)	93%
Random Forest	V3.0 Final (Binário / Rotacionado)	93%
AdaBoost	V3.0 Final (Binário / Rotacionado)	Maior Acurácia (93%)



Os dados demonstram que os métodos clássicos otimizados (como o AdaBoost e o Random Forest) capturaram perfeitamente as fronteiras de decisão da base rotacionada e agrupada em AMD/INTEL. O AdaBoost alcançou a excelência, consolidando-se como o melhor classificador entre todos os avaliados no primeiro bimestre.



6. Conclusão

A execução deste trabalho permitiu concluir que a integridade estrutural das bases de dados determina de forma absoluta o sucesso de modelos de Inteligência Artificial. A aplicação da engenharia de recursos por meio de alinhamento por rotação (V3) e a posterior fusão binária das classes em AMD e Intel provaram-se soluções cirúrgicas. O AdaBoost, juntamente com o Random Forest e o SVM (ambos com 93%), validaram de maneira inequívoca as hipóteses de projeto formuladas pela equipe, provando que a preparação dos dados é frequentemente mais vital do que o algoritmo escolhido. Para finalizar, os representantes finais de cada bimestre são:

- 1- AdaBoost, porém com outros modelos com eficácia similar;
- 2- MLP, que conseguiu alcançar um patamar equivalente.